الجامعة الافتراضية السورية
Syrian Virtual University
مقرر الخوارزميات الذكية
BIA601-Intelligent Algorithms
الفصل الدراسي F25

الخوارزميات الذكية

د. عصام محمد سلمان

إعداد الطلاب

عامر نعيم	AMER_214868
محمد العريضي	MOHAMED_196182
جودي قاسم	JOUDY_259439
نغم شلغين	NAGHAM_231386
محمد أبي خولاني	MOHAMAAD_OBAI_240985
علي ديب	ALI_239162
أحمد العضم	AHMAD_154538
آية مسعود	AYA_175481
سارة طالب	SARAH_226237

مساهمات الأعضاء

تم العمل على الخوارزمية الأولى مع الشرح من قبل الطلاب:

1. جودي قاسم
2. محمد العريضي

تم العمل على الخوارزمية الثانية مع الشرح من قبل الطلاب

1. عامر نعيم
2. نغم شلغين

تم العمل على الخوارزمية الثالثة مع الشرح من قبل الطلاب:

1. أحمد العضم
2. علي ديب

تم العمل على التقرير من قبل الطلاب:

1. آية مسعود
2. سارة طالب

تجهيز ملف README

1. محمد أبي الخوراني

مقدمة عن المشكلة

❖ عنوان المشكلة:

Single-Depot Single-Vehicle Delivery Route Optimization (TSP-like)

وهي تهدف إلى إيجاد أفضل مسار ممكن لمندوب التوصيل لتسليم الطلبات مع تقليل المسافة واختصار الوقت قدر الإمكان

❖ سبب اختيار المشكلة:

بعد التشاور بين أعضاء فريق العمل تم اختيار هذه المشكلة لأنها فكرة قريبة من الواقع كما أنها تعالج تحدياً عملياً تواجهه شركات التوصيل بشكل يومي.

كما تم اختيارها لأنها تتناسب مع موضوع الخوارزميات الذكية حيث يمكننا استخدام هذه الخوارزميات للبحث عن مسارات أفضل من خلال مقارنة عدة حلول واختيار المسار الذي يحقق أقل مسافة ممكنة وأقل وقت للتوصيل.

لنبدأ بشرح عمل كل خوارزمية:

أولاً: شرح الخوارزمية الجينية GA:

تم اعتماد المسافة الإجمالية للمسار كدالة هدف مباشرة بحيث تسعى الخوارزمية إلى تقليل قيمة المسافة واختيار المسارات الأقصر تقوم بحساب المسافة الإجمالية لأي مسار
يبدأ من المستودع (Depot) يمر عبر العُملاء (Customers) بترتيب معين ثم يعود إلى المستودع. رياضيا:

$$D(R) = d(Depot,C1) + \sum_{i=1}^{n-1} d\left(c_{i,}\ C_{i+1}\right) + d\left(C_n, Depot\right)$$

حيث d(A,B) تمثل المسافة الاقيلدية

$$d(A,B) = \sqrt{(X2 - X1)^2 + (Y2 - Y1)^2}$$

Ci رقم العميل في المسار

2. التهيئة الأولية للمجتمع (Population Initialization)
تقوم دالة initialize_population بإنشاء مجتمع أولي يتكون من عدد محدد من الأفراد (pop_size=60).

يمثل كل فرد (إريثروما/جينوم) ترتيباً عشوائياً لزيارة العملاء باستخدام np.random.permutation مما يضمن أن كل عميل يُزار مرة واحدة في كل مسار.

3. الانتخاب أو الاختيار (Selection)
بعد تقييم مسافة كل فرد يتم ترتيب المجتمع تصاعدياً (من المسافة الأقصر والأفضل إلى الأطول).

تقوم دالة select_parents باختيار الآباء من النصف الأفضل من المجتمع (pop_size // 2) لضمان توريث الخصائص الجيدة للأجيال القادمة.

4. GA CROSSOVER

تم استخدام عملية تصالب تحافظ على ترتيب العملاء حيث يتم الاحتفاظ بجزء من مسار الأب الأول ثم استكمال بقية العملاء وفق ترتيب ظهورهم في الأب الثاني مع ضمان عدم تكرار أي عميل

5. Swap Mutation

تعتمد الطفرة على اختيار موضعين عشوائيين داخل المسار وتبديل العميلين الموجودين فيهما بهدف زيادة تنوع الحلول واستكشاف مسارات جديدة

6. الحلقة الرئيسية ومعايير التوقف (Stopping Criteria & Genetic Algorithm Loop)

تدور حلقة while لتوليد الأجيال المتعاقبة حتى تحقق أحد شرطي التوقف:

التوقف المبكر (Early stopping)**:** إذا لم يحدث أي تحسن في أفضل مسافة لفترة زمنية/تقييمات محددة (patience_evals = 2400).

بلوغ ميزانية التقييم القصوى: الوصول إلى الحد الأقصى لعمليات تقييم دالة الهدف (max_evaluations = 18000).

ثانياً: شرح Particle Swarm Optimization (PSO) :

تُعد خوارزمية تحسين سرب الجسيمات (Particle Swarm Optimization – PSO) إحدى خوارزميات التحسين الذكية المستوحاة من السلوك الجماعي للكائنات في الطبيعة مثل حركة أسراب الطيور ومجموعات الأسماك. تعتمد الخوارزمية على مجموعة من الحلول المرشحة يُطلق على كل منها اسم جسيم (Particle) تعمل معًا للبحث عن حل أمثل أو قريب من الأمثل للمشكلة.

في هذا المشروع تم استخدام نسخة متقطعة من الخوارزمية (Discrete PSO) لمعالجة مشكلة تحسين مسار مندوب التوصيل (Delivery Route Optimization). ونظرًا لأن الحلول في هذه المشكلة تمثل ترتيبات محددة للعملاء وليس قيمًا عددية مستمرة فقد تم تعديل آلية حركة الجسيمات التقليدية لتناسب طبيعة المسألة.

1. تمثيل الحل (Solution Representation)

يمثل كل جسيم مسارًا محتملًا لزيارة العملاء ويُعبّر عنه باستخدام قائمة مرتبة تحتوي على أرقام العملاء دون تكرار.

على سبيل المثال إذا كان لدينا أربعة عملاء فقد يكون أحد الحلول:[2، 4، 1، 3] ويعني ذلك أن مندوب التوصيل يزور العميل الثاني أولًا ثم الرابع ثم الأول ثم الثالث.

لا يتم تضمين المستودع (Depot) ضمن التمثيل الداخلي للجسيم وإنما تتم إضافته تلقائيًا عند حساب المسافة بحيث يبدأ المسار من المستودع وينتهي بالعودة إليه.

يضمن هذا التمثيل زيارة كل عميل مرة واحدة فقط مما يحافظ على القيود الأساسية للمشكلة

2. دالة الهدف واللياقة (Fitness Functions & Objective)

الهدف الأساسي في هذه المشكلة هو **تصغير (Minimize)** إجمالي المسافة المقطوعة لتغطية كافة نقاط التوصيل والعودة للمستودع.

تقوم بحساب المسافة الإجمالية لأي مسار (Route) يبدأ من المستودع (Depot) يمر عبر العُملاء (Customers) بترتيب معين ثم يعود إلى المستودع. رياضيا:

$$D(R) = d(Deopt,C1) + \sum_{i=1}^{n-1} d\left(c_i,\ C_{i+1}\right) + d\left(C_n, Depot\right)$$

حيث d(A,B) تمثل المسافة الاقيلدية

$$d(A,B) = \sqrt{(X2 - X1)^2 + (Y2 - Y1)^2}$$

Ci رقم العميل في المسار

N: عدد العملاء

Depot: موقع المستودع

3. آلية عمل الخوارزمية (Algorithm Mechanism)

تعتمد الخوارزمية على مجموعة من الجسيمات (Swarm) يمثل كل جسيم حلًا محتملًا للمشكلة ويتحرك في فضاء الحلول عبر المراحل التالية:

المرحلة الأولى: تهيئة السرب (Swarm Initialization)

يُنشأ مجتمع ابتدائي من الجسيمات باستخدام التبديل العشوائي (Random Permutation) لترتيب العملاء.

تُحسب المسافة الإجمالية لكل مسار ويُسجل لكل جسيم أفضل حل شخصي حققه (PBest) ويُحدد أفضل حل على مستوى السرب بالكامل (GBest).

المرحلة الثانية: حساب الحركة وتحديث السرعة (Velocity Update)

في النسخة المتقطعة تُمثّل السرعة على شكل سلسلة من **عمليات تبديل المواقع (Swap Operations)** لتحويل ترتيب إلى آخر.

تُبنى سرعة الجسيم الجديدة من ثلاثة مكونات رئيسية:

a) **القصور الذاتي (w):** الاحتفاظ بجزء من عمليات التبديل السابقة.
b) **التأثير الشخصي (c_1):** التوجيه نحو أفضل ترتيب شخصي (PBest).
c) **التأثير الاجتماعي (c_2):** التوجيه نحو أفضل ترتيب عام بالسرب (GBest).

المرحلة الثالثة: تحديث موقع الجسيم (Position Update)

تطبيق عمليات التبديل الناتجة على ترتيب العملاء الحالي للحصول على مسار جديد محافظ على عدم تكرار العملاء.

إضافة آلية استكشاف (Exploration) باحتمال محدد لتنفيذ تبديل عشوائي إضافي لزيادة التنوع وتجنب الحلول المحلية الفرعية.

المرحلة الرابعة: تقييم الحلول وتحديث أفضل القيم (Fitness Evaluation)

حساب المسافة الإجمالية للمسار الجديد وتحديث قيمة PBest و GBest في حال تحسن المسافة.

المرحلة الخامسة: التكرار والتوقف (Iteration and Termination)

تتكرر عملية تحديث الجسيمات حتى يتحقق أحد شرطي التوقف:

الوصول إلى الحد الأقصى لتقييمات دالة الهدف.

التوقف المبكر (Early Stopping) عند عدم تحقيق أي تحسن لفترة متتالية محددة.

4. المعاملات المستخدمة (Hyperparameters)

تم ضبط معاملات الخوارزمية كالتالي:

المعامل	القيمة	الوظيفة
w (Inertia)	0.7	معامل القصور الذاتي لعمليات التبديل السابقة.
c1 (Cognitive)	1.5	معامل التأثير الشخصي (PBest).
c2 (Social)	1.5	معامل التأثير الاجتماعي (GBest).
V{max}	10	الحد الأقصى لعدد عمليات التبديل في السرعة.
Exploration Probability	0.10	احتمال تنفيذ عملية تبديل عشوائية إضافية.

4. معايير التقييم (Evaluation Metrics)

تم تقييم أداء الخوارزمية باستخدام المعايير التالية:

1. جودة الحل (Solution Quality): تمثل أقل مسافة إجمالية تم الوصول إليها وتُستخدم لمقارنة جودة المسارات الناتجة.

2. زمن التنفيذ (Execution Time): الوقت المستغرق لتنفيذ الخوارزمية وإيجاد أفضل مسار.

3. سرعة التقارب (Convergence Speed): عدد التكرارات اللازمة للوصول إلى الحل الناتج مع متابعة تغير أفضل مسافة عبر منحنى التقارب (Convergence Curve).

4. عدد تقييمات دالة الهدف (Objective Evaluations): عدد المرات التي تم فيها حساب المسافة الإجمالية للمسارات أثناء التنفيذ.

ثالثاً: شرح خوارزمية مستعمرة النمل (ACO):

تُعد خوارزمية مستعمرة النمل (Ant Colony Optimization – ACO) إحدى خوارزميات التحسين الذكية المستوحاة من سلوك النمل الحقيقي أثناء البحث عن الغذاء. يترك النمل أثناء حركته مادة كيميائية تسمى الفيرومون (Pheromone) وكلما كان الطريق أقصر قطعه النمل ذهاباً وإياباً بسرعة أكبر فتراكم عليه فيرومون أكثر فيصبح أكثر جذباً لبقية النمل. ويُسمى هذا التواصل غير المباشر عبر البيئة Stigmergy.

في هذا المشروع طُبّقت الخوارزمية بصيغة نظام النمل (Ant System) على مشكلة تحسين مسار مندوب التوصيل (Delivery Route Optimization). وتناسب ACO هذه المشكلة بشكل طبيعي لأن كل نملة تبني مساراً كاملاً خطوة بخطوة فتختار في كل خطوة العميل التالي من بين العملاء الذين لم تتم زيارتهم بعد وبذلك يكون كل حل صالحاً دائماً دون الحاجة إلى عمليات تصحيح.

1. تمثيل الحل (Solution Representation)

يمثل كل حل مساراً تبنيه نملة واحدة ويُعبّر عنه بقائمة مرتبة تحتوي على أرقام العملاء دون تكرار وهو التمثيل نفسه المستخدم في GA وPSO.

على سبيل المثال إذا كان لدينا أربعة عملاء فقد يكون أحد الحلول: [2، 4، 1، 3] ويعني ذلك أن المندوب يبدأ من المستودع ثم يزور العميل الثاني فالرابع فالأول فالثالث ثم يعود إلى المستودع.

تبدأ كل نملة من المستودع (Depot) ولا يُضاف المستودع إلى القائمة الداخلية وإنما يُضاف تلقائياً في بداية المسار ونهايته عند حساب المسافة.

بالإضافة إلى ذلك تحتفظ الخوارزمية بمصفوفة فيرومون (Matrix Pheromone) بحجم (N+1)×(N+1) تمثل مدى جاذبية كل وصلة (Edge) بين نقطتين وبمصفوفة مسافات تُحسب مرة واحدة في البداية.

يضمن هذا التمثيل زيارة كل عميل مرة واحدة فقط لأن النملة لا تختار إلا من بين العملاء غير المزارين.

2. دالة الهدف واللياقة (Fitness Functions & Objective)

الهدف الأساسي في هذه المشكلة هو **تصغير (Minimize)** إجمالي المسافة المقطوعة لتغطية كافة نقاط التوصيل والعودة للمستودع وهي دالة الهدف نفسها المستخدمة في GA وPSO.

تقوم بحساب المسافة الإجمالية لأي مسار (Route) يبدأ من المستودع (Depot) يمر عبر العملاء (Customers) بترتيب معين ثم يعود إلى المستودع. رياضياً:

$$D(R) = d(Depot, C_1) + \sum_{i=1}^{N-1} d(C_i, C_{i+1}) + d(C_N, Depot)$$

حيث d(A,B) تمثل المسافة الإقليدية:

$$d(A,B) = \sqrt{(X_2 - X_1)^2 + (Y_2 - Y_1)^2}$$

C_i: رقم العميل في المسار.

N: عدد العملاء.

Depot: موقع المستودع.

وتستخدم ACO المسافة أيضاً بطريقة ثانية هي **المعلومة الاستدلالية (Heuristic Information)** التي تعبّر عن جاذبية الانتقال من النقطة i إلى النقطة j:

$$\eta_{ij} = \frac{1}{d_{ij}}$$

أي أن العميل الأقرب أكثر جاذبية للنملة.

3. آلية عمل الخوارزمية (Mechanism Algorithm)

تعتمد الخوارزمية على مستعمرة من النمل (Colony) تبني كل نملة في كل دورة مساراً كاملاً ثم تتعلم المستعمرة من المسارات الجيدة عبر الفيرومون من خلال المراحل التالية:

المرحلة الأولى: تهيئة الفيرومون (Pheromone Initialization)

- تُعطى كل وصلة بين نقطتين القيمة نفسها $\tau_0 = 1$ لذلك تعتمد النملات في الدورة الأولى على المسافة فقط.
- تُحسب مصفوفة المسافات ومصفوفة المعلومة الاستدلالية $\eta = 1/d$ مرة واحدة في البداية.

المرحلة الثانية: بناء الحلول (Solution Construction)

• تنطلق كل نملة من المستودع وفي كل خطوة تختار العميل التالي j من بين العملاء غير المزارين باحتمال:

$$P_{ij} = \frac{{\tau_{ij}}^{\alpha} \cdot {\eta_{ij}}^{\beta}}{\sum_{k \in unvisited} {\tau_{ik}}^{\alpha} \cdot {\eta_{ik}}^{\beta}}$$

• يتحكم α بأهمية الفيرومون (خبرة المستعمرة) ويتحكم β بأهمية المسافة (المعرفة المسبقة بالمشكلة).
• يتم الاختيار بطريقة عجلة الروليت (Roulette Wheel) وبعد زيارة جميع العملاء تعود النملة إلى المستودع.

المرحلة الثالثة: تقييم الحلول (Fitness Evaluation)

• تُحسب المسافة الإجمالية لمسار كل نملة باستخدام دالة الهدف نفسها وتُعد كل نملة تقييماً واحداً لدالة الهدف (مثل فرد واحد في GA أو جسيم واحد في PSO).
• يُحدَّث أفضل مسار عام (Best-So-Far) إذا وُجد مسار أقصر.

المرحلة الرابعة: تبخير الفيرومون (Evaporation)

• بعد انتهاء جميع النملات يُخفَّض الفيرومون على جميع الوصلات بنسبة ρ:

$$\tau_{ij} \leftarrow (1 - \rho) \cdot \tau_{ij}$$

• يمنع التبخير الخوارزمية من التعلق الدائم بمسار قديم ويتيح نسيان الوصلات السيئة تدريجياً.

المرحلة الخامسة: تحديث الفيرومون (Pheromone Deposit)

• تضيف كل نملة k كمية من الفيرومون على كل وصلة استخدمتها تتناسب عكسياً مع طول مسارها L_k:

$$\tau_{ij} \leftarrow \tau_{ij} + \sum_{k} \frac{Q}{L_k}$$

• أي أن المسارات الأقصر تترك فيروموناً أكثر فتزداد احتمالية اختيار وصلاتها من قبل النملات في الدورة التالية.

المرحلة السادسة: التكرار والتوقف (Iteration and Termination)

تتكرر الدورة (بناء ← تقييم ← تبخير ← تحديث) حتى يتحقق أحد شرطي التوقف:

• الوصول إلى الحد الأقصى لتقييمات دالة الهدف (18,000 تقييم = 300 دورة × 60 نملة).
• التوقف المبكر (Early Stopping) عند عدم تحسن أفضل مسار خلال 2,400 تقييم متتالٍ (40 دورة) بالقاعدة نفسها المستخدمة في GA وPSO.

4. المعاملات المستخدمة (Hyperparameters)

تم ضبط معاملات الخوارزمية كالتالي:

المعامل	القيمة	الوظيفة
n_ants **(عدد النمل)**	60	عدد المسارات التي تُبنى في كل دورة (مساوٍ لحجم المجتمع في GA والسرب في PSO).
α (alpha)	1.0	أهمية الفيرومون في قاعدة الاختيار.
β (beta)	3.0	أهمية المسافة (η = 1/d) في قاعدة الاختيار؛ قيمة أكبر تعني تفضيلاً أقوى للعملاء الأقرب.
ρ (rho)	0.10	معدل التبخير: يتبخر 10% من الفيرومون بعد كل دورة.
Q	100	ثابت إضافة الفيرومون: تضيف النملة Q / L على كل وصلة في مسارها.
τ_0 (tau0)	1.0	قيمة الفيرومون الابتدائية على كل وصلة.

اختيرت هذه القيم من القيم الشائعة في أدبيات ACO وما عُرض في المادة وتم تثبيتها قبل تشغيل التجارب دون ضبطها على النتائج حفاظاً على عدالة المقارنة.

5. معايير التقييم (Evaluation Metrics)

تم تقييم أداء الخوارزمية باستخدام المعايير التالية:

1. جودة الحل (Solution Quality): أقل مسافة إجمالية تم الوصول إليها.

2. زمن التنفيذ (Execution Time): الوقت المستغرق لتنفيذ الخوارزمية وإيجاد أفضل مسار.

3. سرعة التقارب (Convergence Speed): عدد الدورات حتى التوقف مع متابعة تغير أفضل مسافة عبر منحنى التقارب (Curve Convergence).

4. عدد تقييمات دالة الهدف (Evaluations Objective): عدد المسارات التي تم حساب مسافتها أثناء التنفيذ.

القيم المشتركة بين الخوارزميات الثلاث لدقة المقارنة:

المعامل	القيمة	الوظيفة
Population / Swarm / Colony Size	60	عدد الأفراد في GA والجسيمات في PSO والنمل في ACO.
Evaluation Budget	18,000	الحد الأقصى لعدد تقييمات دالة الهدف.
Patience Evals	2,400	عدد التقييمات دون تحسن قبل الإيقاف المبكر.

التجارب العملية والمقارنة:

تم تقييم الخوارزميات الثلاث GA و PSOو ACOباستخدام ثلاث مجموعات بيانات بأحجام مختلفة: 10 و30 و100 عميل.

لدراسة استقرار النتائج عند إعادة التجربة تم تنفيذ كل خوارزمية ثلاث مرات مستقلة باستخدام قيم Seedsمختلفة (42 123 456). تمت أتمتة عمليات التشغيل بحيث تُنفّذ الجولات الثلاث دون تدخل يدوي.

تم تثبيت بيانات الاختبار ومعلمات الخوارزميات وميزانية التقييم وشروط التوقف في جميع الجولات بهدف جعل المقارنة أكثر اتساقاً.

بعد انتهاء التشغيلات تمت مقارنة المسافات الناتجة وحساب المتوسط الحسابي والانحراف المعياري لكل خوارزمية وحجم بيانات. كما تمت مقارنة زمن التنفيذ وعدد تقييمات دالة الهدف وسرعة التقارب.

❖ المقارنة بين الخوارزميات الثلاث عند حجم بيانات صغير 10 عملاء

10 customers

Algorithm	GA	PSO	ACO
Run			
1	272.8705	273.8102	260.9292
2	268.3209	272.1439	260.9292
3	266.7841	277.6992	260.9292

❖ المقارنة بين الخوارزميات الثلاث عند حجم بيانات متوسط 30 عميل:

30 customers

Algorithm	GA	PSO	ACO
Run			
1	613.9130	650.4607	471.6965
2	617.5412	808.2488	471.4957
3	680.6879	682.4226	471.6965

❖ المقارنة بين الخوارزميات الثلاث عند حجم بيانات متوسط 100 عميل:

100 customers

Algorithm	GA	PSO	ACO
Run			
1	2266.3474	2435.7122	820.1527
2	2205.5848	2473.4980	827.4002
3	2011.8670	2466.0836	842.0185

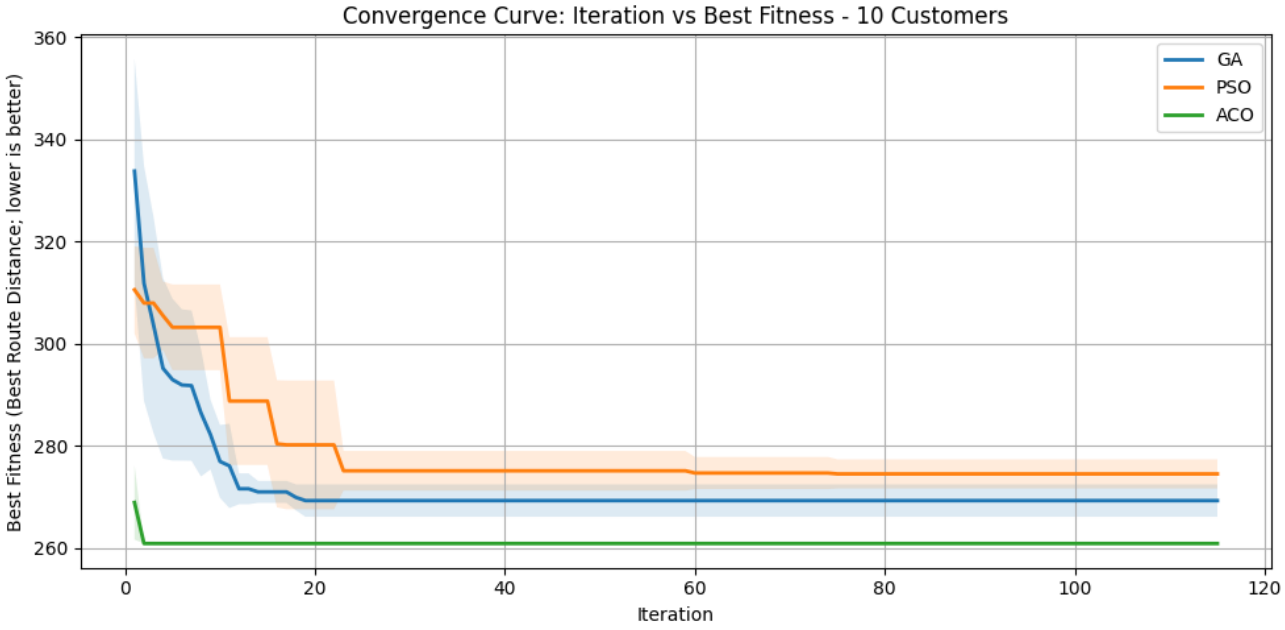


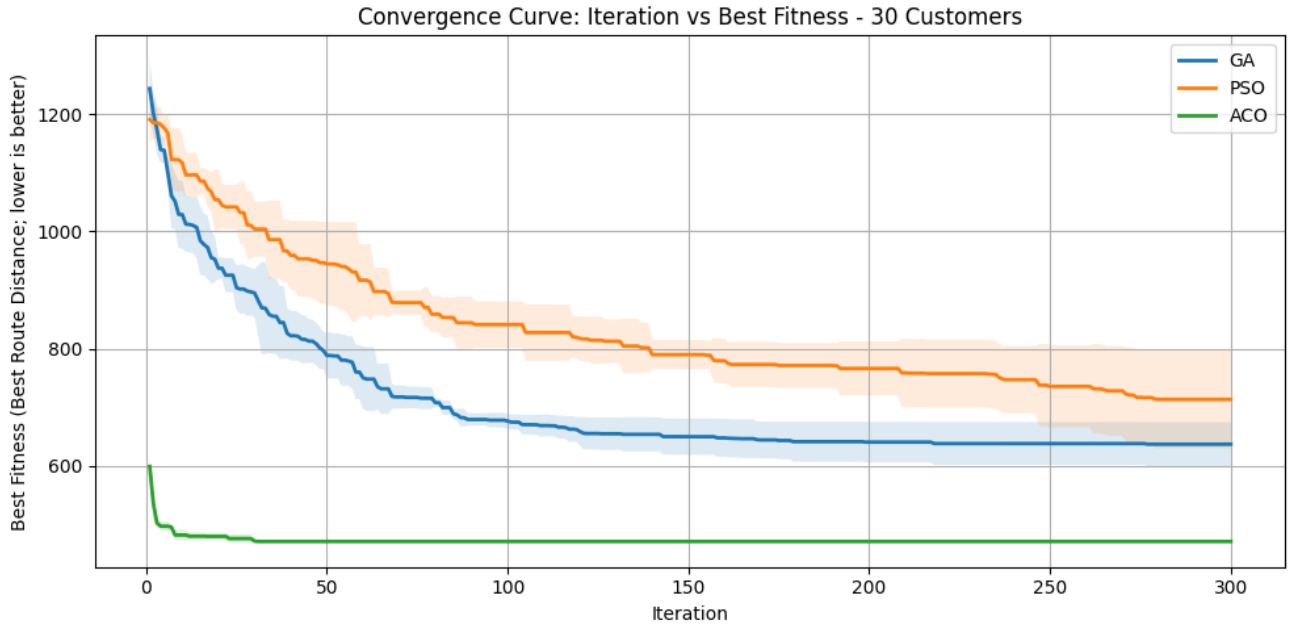
جداول النتائجResults

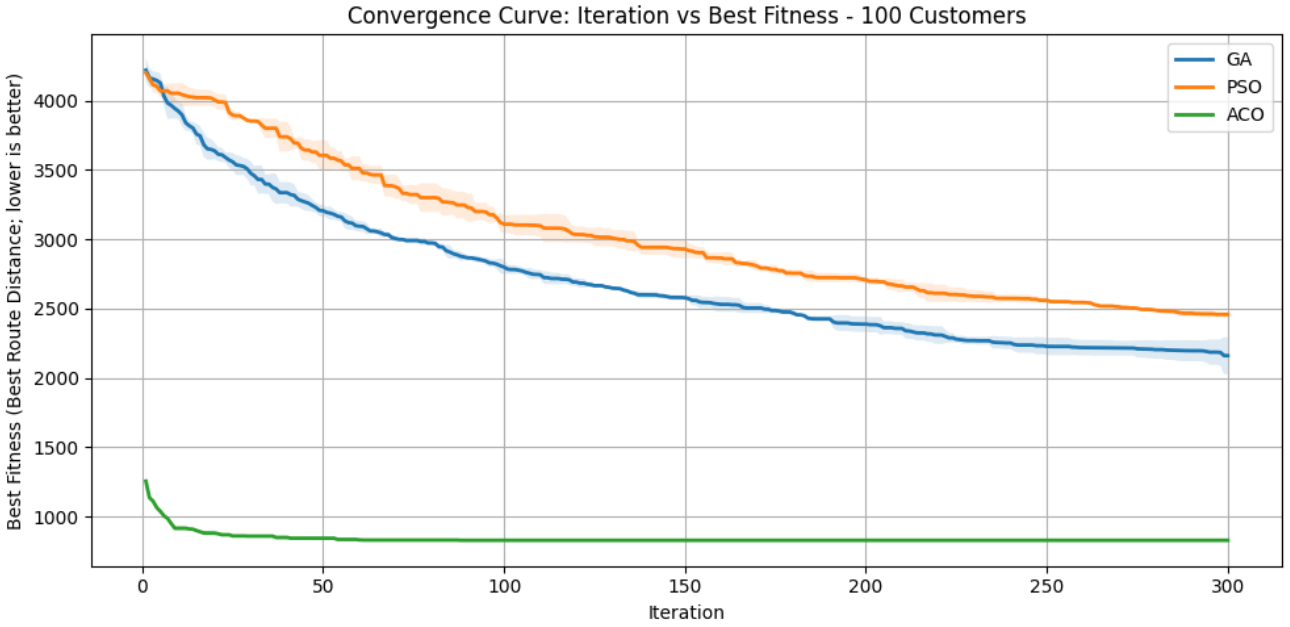
Statistical comparison across the three independent runs

	Problem_Size	Algorithm	Runs	Best	Worst	Mean	Std_Dev	Mean_Time_s	Mean_Evaluations	Mean_Iterations	CV_%
0	10	ACO	3	260.9292	260.9292	260.9292	0.0000	1.2733	2520.0	42.0000	0.0000
1	10	GA	3	266.7841	272.8705	269.3252	3.1650	0.4232	3420.0	57.0000	1.1752
2	10	PSO	3	272.1439	277.6992	274.5511	2.8508	1.3311	4620.0	76.0000	1.0384
3	30	ACO	3	471.4957	471.6965	471.6296	0.1160	4.4925	4080.0	68.0000	0.0246
4	30	GA	3	613.9130	680.6879	637.3807	37.5490	2.2220	14560.0	242.6667	5.8911
5	30	PSO	3	650.4607	808.2488	713.7107	83.4175	5.7027	15980.0	265.3333	11.6879
6	100	ACO	3	820.1527	842.0185	829.8572	11.1380	20.1439	6460.0	107.6667	1.3422
7	100	GA	3	2011.8670	2266.3474	2161.2664	132.9028	5.9285	18000.0	300.0000	6.1493
8	100	PSO	3	2435.7122	2473.4980	2458.4313	20.0215	7.4956	18000.0	299.0000	0.8144

منحنيات Iteration → Best Fitness



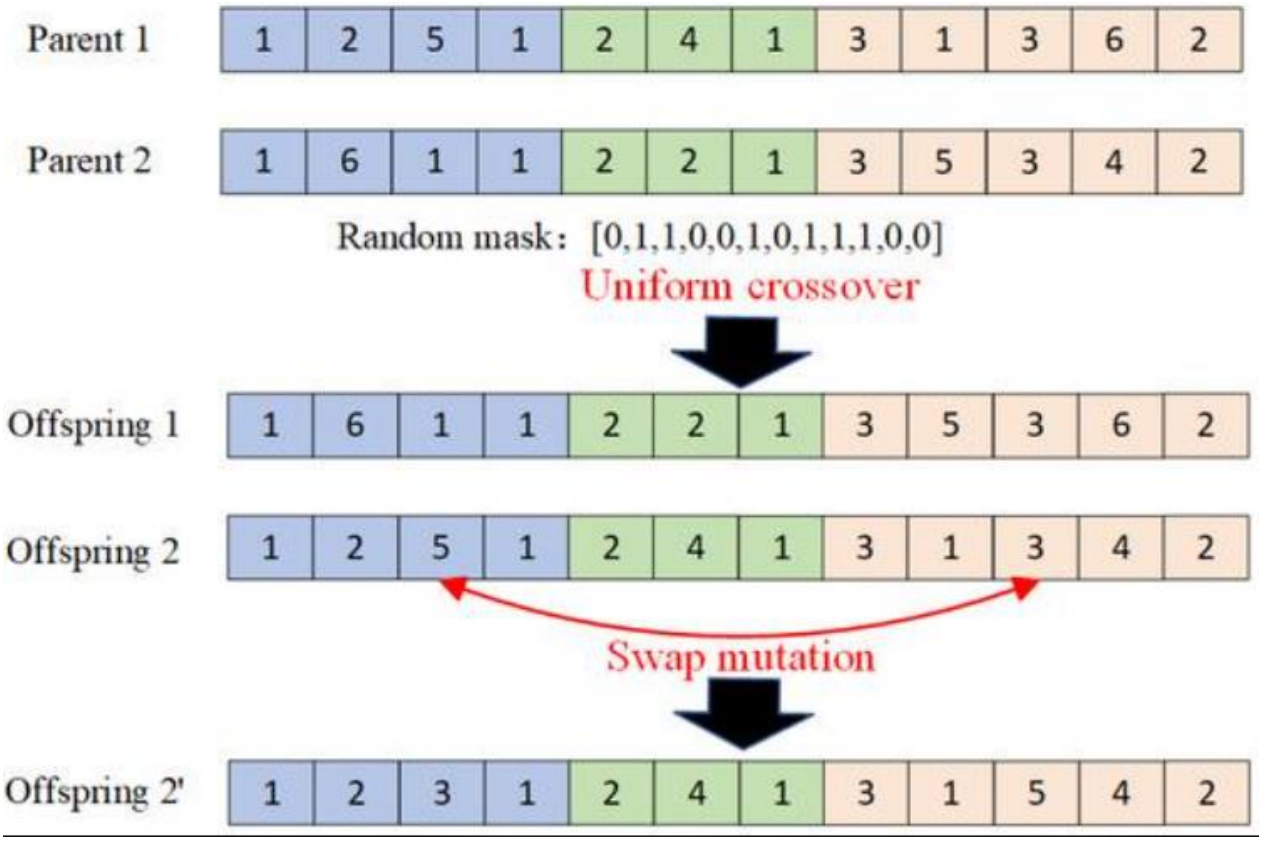




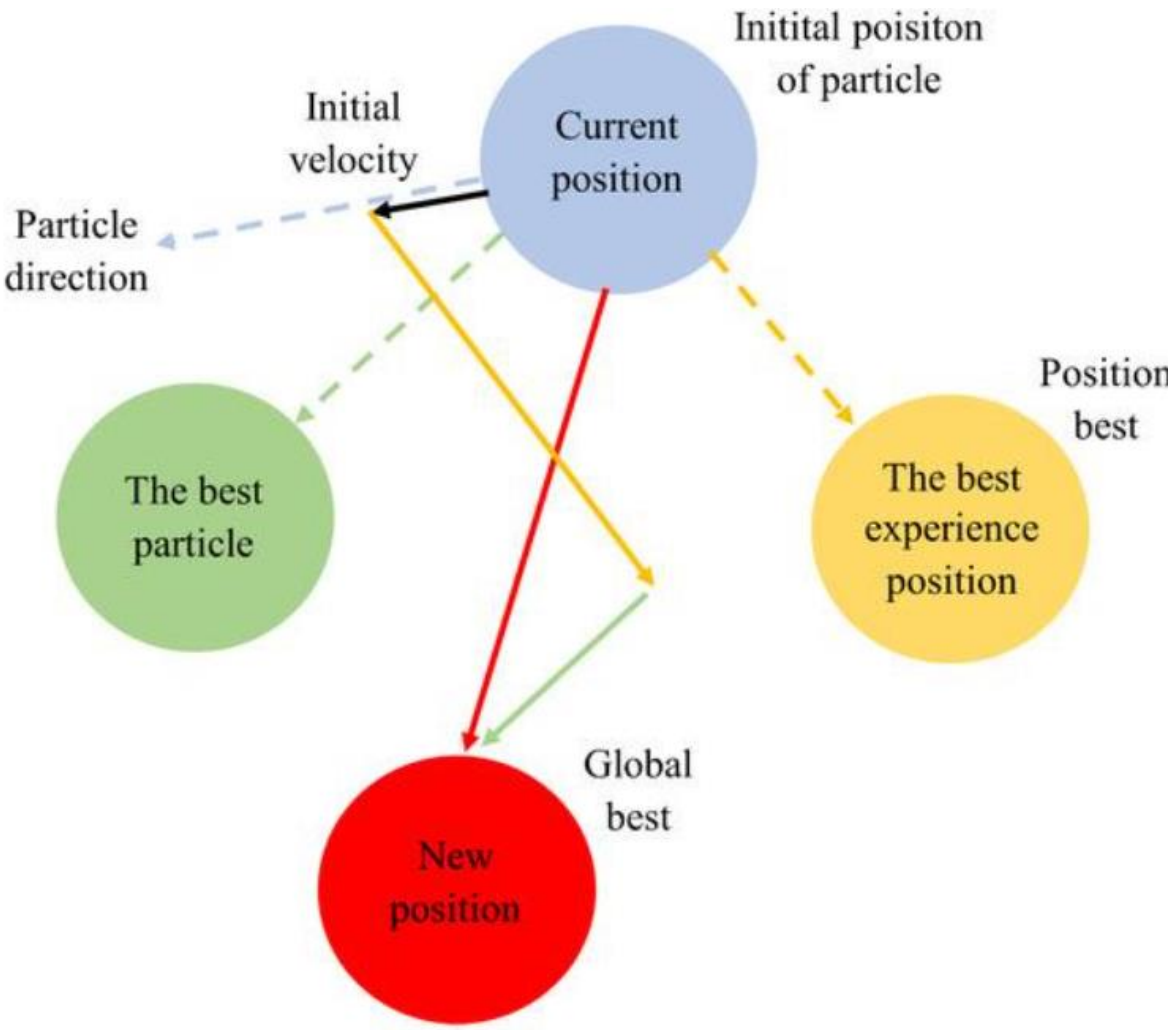
مناقشة النتائج:

أظهرت المقارنة بين الخوارزميات الثلاث أن اختلاف الأداء يعود بشكل أساسي إلى اختلاف آلية تمثيل الحلول وطريقة استكشاف فضاء البحث والتعامل مع طبيعة مشكلة مسارات التوصيل.

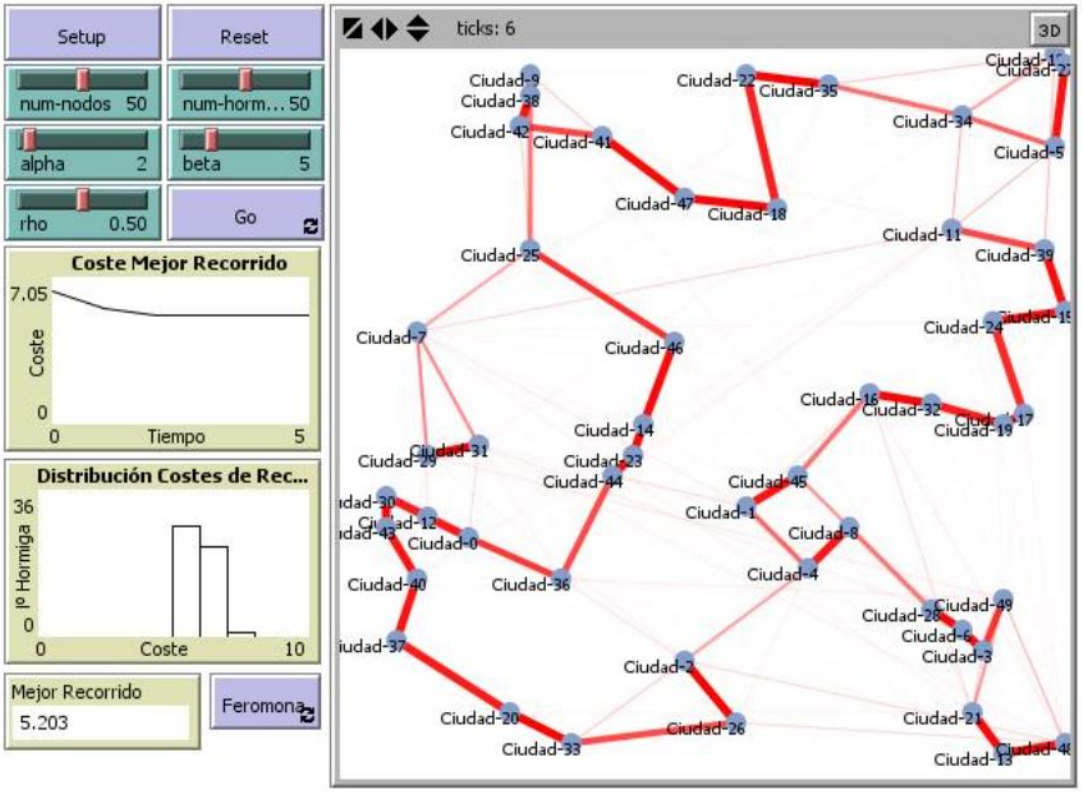
تعتمد الخوارزمية الجينية (GA) على عمليات الاختيار والتقاطع والطفرة لتوليد ترتيبات جديدة للعملاء. وتتميز بقدرتها على استكشاف فضاء حلول واسع إلا أن هذا الاستكشاف قد يحتاج إلى وقت وتقييمات أكثر كما أن نتائجها قد تتأثر باختلاف التهيئة العشوائية ومعاملات التقاطع والطفرة.



أما خوارزمية سرب الجسيمات(PSO) فتعتمد على توجيه الحلول نحو أفضل موقع شخصي وأفضل موقع جماعي. ورغم بساطة آلية التحديث فإن تطبيقها على مشكلة ترتيب متقطعة مثل TSP يتطلب تمثيلاً خاصاً للحركة باستخدام عمليات التبديل وقد يؤدي الاعتماد الكبير على أفضل حل جماعي إلى تقليل تنوع الحلول والوصول المبكر إلى حلول محلية.



في المقابل تعتمد خوارزمية مستعمرة النمل (ACO) على تمثيل شبكي للمشكلة وتستخدم الفيرومون والمعلومة الاستدلالية المرتبطة بالمسافة لتوجيه عملية بناء المسارات. وهذا يجعل آلية عملها مناسبة لطبيعة مشكلة التوصيل لكنه لا يمنع احتمال حدوث ركود مبكر إذا تركز الفيرومون بسرعة على مسارات غير مثالية.



تمت أيضاً دراسة استقرار النتائج من خلال ثلاث تشغيلات مستقلة لكل خوارزمية. وتم استخدام المتوسط والانحراف المعياري لمقارنة جودة الحلول ومدى تقارب النتائج. وتوضح هذه المقارنة أن تقييم الخوارزمية لا يعتمد فقط على أفضل مسافة حققتها بل يشمل أيضاً قدرتها على تكرار أداء متقارب عبر تشغيلات مختلفة.

بشكل عام يوضح الاختلاف بين النتائج أن ملاءمة آلية الخوارزمية لطبيعة المشكلة وتوازنها بين الاستكشاف والاستغلال ومعاملاتها المستخدمة جميعها عوامل تؤثر في جودة الحل وسرعة الوصول إليه واستقرار نتائجه.

جدول نقاط القوة والضعف لكل خوارزمية

الخوارزمية	نقاط القوةStrengths	نقاط الضعفWeaknesses
GA	استكشاف واسع لفضاء الحلول مرونة في إضافة قيود وتتعامل مباشرة مع ترتيب العملاء.	قد تحتاج وقتاً وتقييمات كثيرة حساسة لمعاملات التقاطع والطفرة وقد تتذبذب نتائجها بين التشغيلات.
PSO	آلية تحديث واضحة تستفيد من أفضل حل شخصي وجماعي وعدد معلماتها أقل نسبياً.	تكييفها مع المسائل المتقطعة أصعب وقد تقع في الحلول المحلية أو تفقد تنوع البحث.
ACO	تمثيل طبيعي للمسارات والروابط تستفيد من الفيرومون والمسافة ويمكن أن تصل إلى حلول جيدة بعدد تقييمات أقل.	قد يحدث ركود مبكر وتتأثر بمعاملات الفيرومون والتبخير والمعلومة الاستدلالية وتحتاج إلى تخزين مصفوفات المسافات والفيرومون.

الملخص

بناءً على نتائج التجارب الثلاث تمت مقارنة الخوارزميات GA و PSOو ACOمن حيث جودة الحل وزمن التنفيذ وسرعة التقارب واستقرار النتائج.

أظهرت النتائج أن الخوارزمية ACOحققت أفضل متوسط لمسافة المسار في الاحجام الثلاث و سجلت الخوارزمية ACO أقل انحراف معياري مما يشير إلى تقارب أكبر في نتائج تشغيلاتها.

كما أظهرت مقارنة زمن التنفيذ وعدد تقييمات دالة الهدف اختلاف الكفاءة الحسابية بين الخوارزميات. وبناءً على هذه المؤشرات يمكن اعتبار الخوارزمية ACO الأنسب للمشكلة ضمن إعدادات التجربة المستخدمة مع مراعاة أن الأداء قد يختلف باختلاف حجم البيانات ومعلمات الخوارزمية.